GE2340 数据分析与基线结果

技术证据材料｜2026 年 11 月 3 日｜已依据提交版 Phase 1 核实回归方法

本报告整理数据集、探索性分析、实验设置和基线结果，供组员编写团队报告。连续值预测的数据准备已完成，分类目标定义见第 6 节，回归方法与已提交的 Phase 1 方案一致。

1 数据集与数据质量

- 来源：Charlotte Bennett1234 在 Kaggle 发布的 Lifestyle Factors and Their Impact on Students，第 3 版。原始文件包含 2,000 行、9 列。
- 预测目标 Grades 保留原始单位。完整数据的观测值范围为 5.60–10.00。
- 输入变量为 Study_Hours_Per_Day、Extracurricular_Hours_Per_Day、Sleep_Hours_Per_Day、Social_Hours_Per_Day 和 Physical_Activity_Hours_Per_Day，单位均为小时/天。
- Student_ID 仅用于保留记录身份。Gender 和 Stress_Level 不作为模型输入，以对应 Phase 1 的五项输入方案。

质量检查	结果
原始文件缺失单元格	0
完全重复行 / 重复学生 ID	0 / 0
删除行数 / 插补行数	0 / 0
保留记录数	2,000
每日时长	五项合计 24 小时（浮点容差内）

数据检查涵盖字段结构、数值是否有限、ID 是否唯一，以及时长是否处于 0–24 小时。全部记录均予保留，未作插补。训练集的四分位距（IQR）标记用于描述潜在异常值。

证据：outputs/quality_audit.json；data/raw/student_lifestyle_dataset..csv；src/run_pipeline.py。

2 数据准备与描述统计

- 使用固定随机种子 2340，先将 20%的记录划为测试集，再从剩余 80%中抽取 25%作为验证集。最终训练集包含 1,200 条记录，验证集和测试集各 400 条。
- 探索图和相关系数仅基于训练集计算。StandardScaler 在训练集输入变量上拟合，随后原样应用于验证集和测试集；Grades 未作标准化。
- 共享数据保留全部五项输入。仅线性回归基线使用四项输入，并以体育活动作为参照活动。

训练变量	均值	样本标准差	最小值	最大值
学习	7.494	1.442	5.000	10.000
课外活动	1.984	1.136	0.000	4.000
睡眠	7.496	1.459	5.000	10.000
社交	2.720	1.702	0.000	6.000
体育活动	4.306	2.475	0.000	13.000
Grades	7.777	0.763	5.600	9.820

训练样本量 n = 1,200。时长单位为小时/天，Grades 保留原始单位。样本标准差以 n−1 为分母；StandardScaler 采用总体标准差约定，因此表中的标准差与实际缩放参数不同。

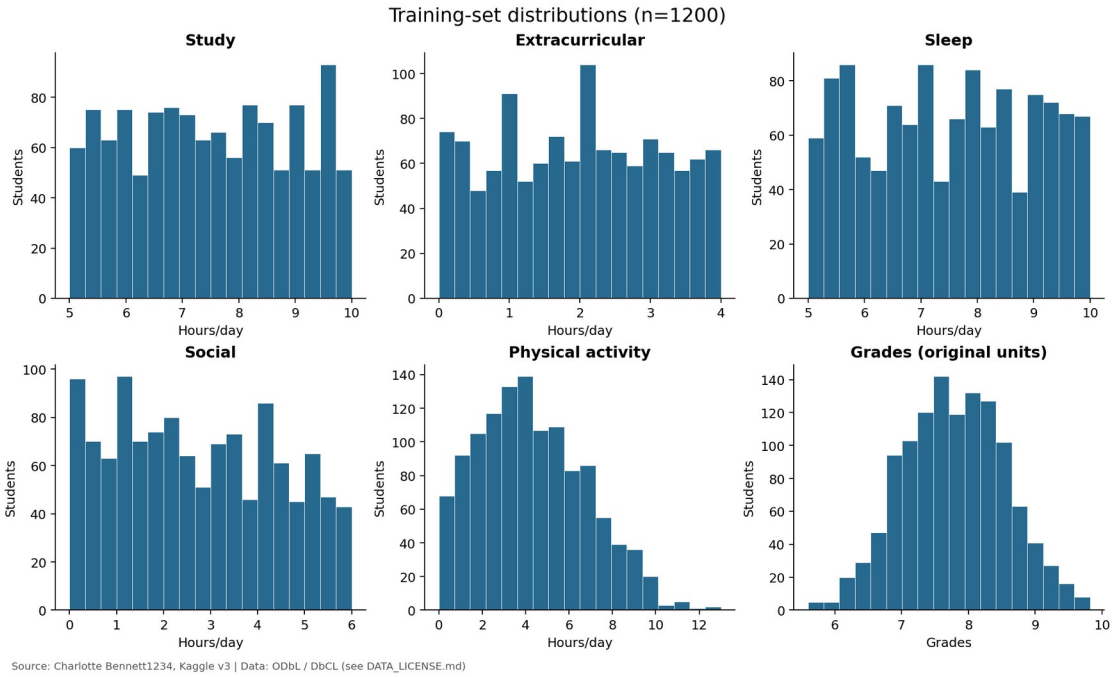
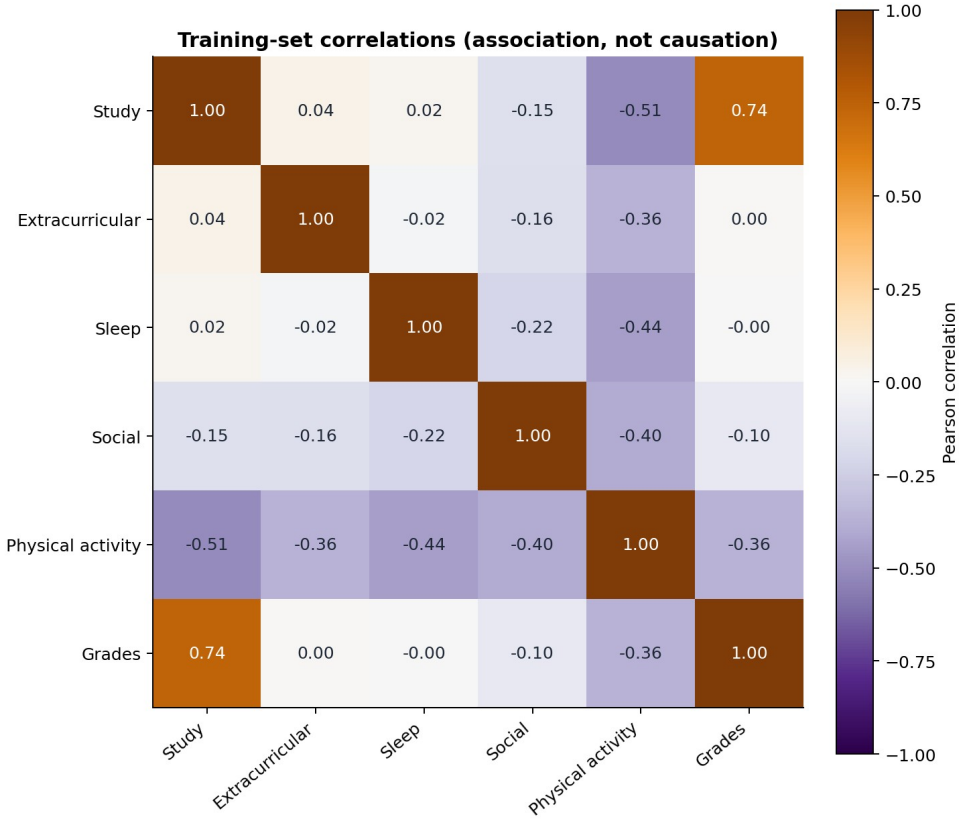


图 1 训练集分布，展示观测范围和分布形状。

3 探索性关系及解释



Source: Charlotte Bennett1234, Kaggle v3 | Data: ODbL / DbCL (see DATA_LICENSE.md)

图 2 训练集 Pearson 相关系数，n = 1,200。图内保留数据来源。

输入变量	与 Grades 的相关系数
学习	0.7391
体育活动	−0.3614
社交	−0.1009
课外活动	0.0024
睡眠	−0.0015

- 在所测量的输入变量中，学习时长与 Grades 的正线性相关最强。睡眠和课外活动与 Grades 的边际相关系数接近零。
- 五类活动合计 24 小时，一种活动增加必然伴随一种或多种其他活动减少。学习与体育活动的相关系数为 −0.5115。

证据：outputs/train_correlations.csv。原数据包中的散点图从另一角度呈现同一训练样本的关系。

4 线性回归与基线评估

- 均值基线对每条记录均预测 7.777125，该值为 1,200 条训练记录的 Grades 均值。
- 线性模型采用带截距的 scikit-learn LinearRegression，以普通最小二乘法（OLS）拟合。该平方误差目标与提交版 Phase 1 的均方误差（MSE）目标一致。模型使用未标准化的训练时长，直接输出以 Grades 原始单位表示的预测值。
- 五项时长之和为 24，中心化训练输入矩阵的秩为 4。将体育活动设为参照，可消除线性模型中的冗余系数，其信息仍由总时长约束体现。

子集	模型	MAE	RMSE	R^2
训练	线性回归	0.4067	0.5131	0.5474
训练	均值基线	0.6234	0.7626	0.0000
验证	线性回归	0.4104	0.5183	0.5147
验证	均值基线	0.6049	0.7442	-0.0005
测试	线性回归	0.3725	0.4731	0.5403
测试	均值基线	0.5659	0.6994	-0.0044

MAE 衡量平均绝对预测误差，RMSE 衡量均方根误差。二者均以 Grades 原始单位表示，数值越低，误差越小。R^2 将平方预测误差与使用评估子集自身均值预测时的误差比较，数值越高越好，也可能为负。

- 线性回归在测试集上的 MAE 为 0.372452，均值基线为 0.565948，约降低 34.2%；测试集 R^2 为 0.540324。
- 训练集和验证集 MAE 分别为 0.406691 和 0.410385，模型在两个子集上的预测误差接近。

Phase1_Proposal.pdf 第 1 页规定使用均方误差，并通过令导数为零求取最优参数。当前 OLS 方法符合该目标。

5 验证集诊断与实验状态

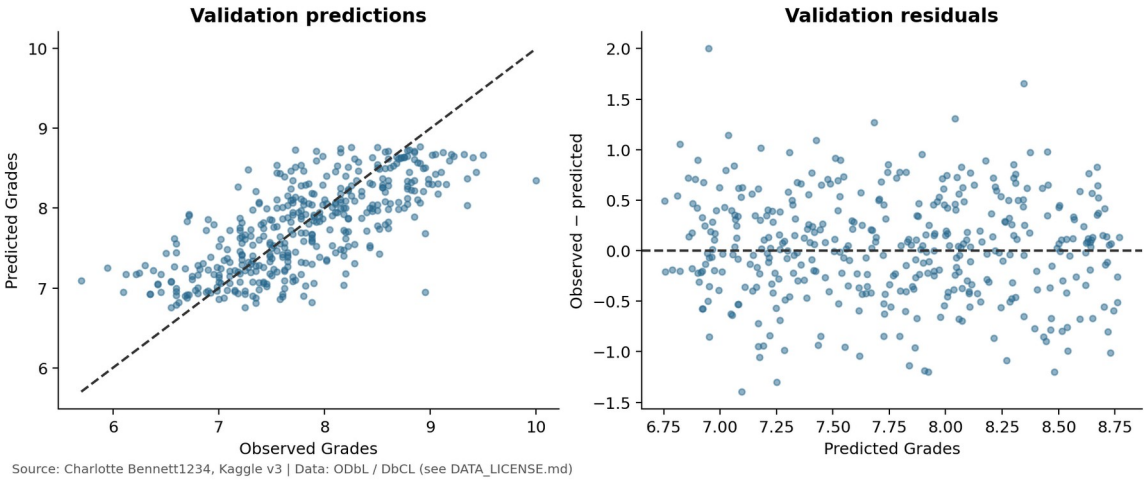


图 3 验证集诊断，n = 400。残差为观测 Grades 减去预测值。

- 数据的原始采集方法及真实或合成来源尚未核实。
- OLS 模型和均值基线已按固定数据划分完成评估。
- 第 6 节定义分类目标。Softmax 和神经网络结果尚待补充，包括相应分类任务的准确率和 Macro-F1。

证据与来源

原始数据：Charlotte Bennett1234. Lifestyle Factors and Their Impact on Students. Kaggle，第 3 版。https://www.kaggle.com/datasets/charlottebennett1234/lifestyle-factors-and-their-impact-on-students

数据许可条款：Open Database License 1.0 和 Database Contents License 1.0。https://opendatacommons.org/licenses/odbl/1-0/ 及 https://opendatacommons.org/licenses/dbcl/1-0/。图表及衍生数据表保留来源标注。

可复现证据：metrics.csv；regression_model.json；train_descriptive_statistics.csv；train_correlations.csv；processed/split_manifest.csv；processed/preprocessor.json；src/run_pipeline.py。数据包包含原始来源元数据及可运行流程。

项目状态

- 第 6 节的等级边界已固定。
- 回归基线采用平方误差 OLS 目标，在 24 小时固定总和约束下使用四项输入。
- 分类器和神经网络结果尚待整合至团队报告。

6 项目自定义分类目标

本项目根据训练集分布定义相对等级。F 表示最低相对组，不代表官方不及格类别。

训练集第 20、40、60 和 80 百分位数为 7.10、7.55、8.00 和 8.45。这些边界固定后原样应用于验证集和测试集。相同分数归入同一等级，因此各组人数可能不同。

等级	Grades 区间	训练	验证	测试
F	Grades < 7.10	238	69	59
D	7.10 ⩽ Grades < 7.55	236	79	78
C	7.55 ⩽ Grades < 8.00	234	99	104
B	8.00 ⩽ Grades < 8.45	249	62	75
A	Grades ⩾ 8.45	243	91	84

上述区间定义了分类标签。

等级边界由训练集计算。加入分类任务时，v1 测试集回归结果已被查看。

共享数据包包含数据划分、预处理参数和分类标签。

多数类基线

多数类基线始终预测训练集中数量最多的类别 B（1,200 条中 249 条），用于比较后续分类器。

子集	准确率	Macro-F1	平衡准确率
训练	20.75%	0.06874	0.20
验证	15.50%	0.05368	0.20
测试	18.75%	0.06316	0.20

Macro-F1 为各类 F1 的等权平均；平衡准确率为各类召回率的平均。证据：v2 的 outputs/class_counts.csv 和 outputs/classification_metrics.csv。